


1. İstatistiğe ve Veri Analizine Giriş


1.4. Değişkenlik Ölçüleri

Değişkenlik ölçütleri verinin nasıl bir dağılım gösterdiği ile ilgili sayısal değerler verir.



Örneklem konum ölçüleri (**ortalama**, **medyan**), bir veri setinin doğasını tam olarak özetlemek için yeterli değildir.

Örnek olarak, aşağıda gösterilen A ve B veri setlerini karşılaştıralım:



Her iki veri seti de ikişer örneklem içermektedir ve bu örneklemelerin ortalamaları arasındaki **fark yaklaşık olarak aynıdır**.

Buna rağmen, B veri seti, örneklemelerin alındığı popülasyonlar arasında çok daha keskin bir karşıtlık (fark) sağlıyor gibi görünmektedir.

Bunun temel sebebi, A ve B veri setlerindeki örneklemelerin değişkenliğinin birbirinden önemli ölçüde farklı olmasıdır.

Değişkenlik Ölçüleri (Measures of Variability):

- Örneklem açıklığı
- Örneklem varyansı
- Örneklem standart sapması

Örneklem açıklığı

Merkezi eğilim veya konum ölçülerinde olduğu gibi, yayılımı veya değişkenliği ölçmek için de birçok farklı yöntem mevcuttur.

Örneklem açıklığı, bu ölçüler arasındaki muhtemelen en basit olanıdır.

$$\text{Örneklem açıklığı} = X_{max} - X_{min}.$$

Örneklem varyansı ve örneklem standart sapması

Yayılmı ölçmek için **en sık** kullanılan yöntem örneklem standart sapmasıdır.

Örneklem değerleri $x_1, x_2, \dots, x_n$ olsun.

Örneklem Varyansı (s^2):

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

Örneklem Standart Sapması (s):

$$s = \sqrt{s^2} = \sqrt{\sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}}$$

- Burada $\bar{x}$ örneklem ortalamasını, n ise örneklemdeki gözlem sayısını temsil eder.
- $n - 1$ ifadesi **serbestlik derecesi** olarak adlandırılır.

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

Örneklem standart sapması, verilerin yayılımını doğrudan gösteren bir ölçüdür.

Veri setindeki değişkenlik arttıkça, her bir değerin ortalamadan farkı da büyüyeceğinden örneklem varyansı (s^2) daha büyük değerler alır.

Serbestlik derecesi, varyansı hesaplamak için elimizde bulunan "bağımsız" bilgi sayısını temsil eder.

Örneğin, veri kümesi (5, 17, 6, 4) ün örneklem varyansı ya da standart sapmasını hesaplayalım:

Örneklem ortalaması $\bar{x} = 8$

Varyans hesabı için aşağıdaki işlemleri göz önüne alalım:

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

$$(5 - 8)^2 + (17 - 8)^2 + (6 - 8)^2 + (4 - 8)^2 = (-3)^2 + 9^2 + (-2)^2 + (-4)^2.$$

Parantez içindeki değerlerin toplamı sıfırdır.

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

$$(-3)^2 + 9^2 + (-2)^2 + (-4)^2.$$

$$(-3) + 9 + (-2) + (-4) = 0$$

Bir örneklemdaki her bir değerin ortalamadan farklarının (sapmaların) toplamı her zaman **sıfıra** eşit olmak zorundadır. Bu matematiksel kural, veri setindeki bağımsız bilgi sayısını kısıtlar.

Örnek Veri Seti: (5, 17, 6, 4)

Örneklem Ortalaması: $\bar{x} = 8$

Toplamın Sıfır Olduğunun Gösterimi:

Her bir değerin ortalamadan farkını alıp topladığımızda sonuç her zaman sıfır çıkar:

$$(5 - 8) + (17 - 8) + (6 - 8) + (4 - 8) = 0$$

$$(-3) + 9 + (-2) + (-4) = 0$$

x_4 Değerinin Belirlenmesi:

Eğer örneklemdaki sonuncu değerin (x_4) ne olduğunu bilmeseydik bile, toplamın sıfır olması kuralı sayesinde bu değeri hesaplayabilirdik:

$$(-3) + 9 + (-2) + (x_4 - 8) = 0$$

$$(x_4 - 8) = -4$$

$$x_4 = 4$$

Sonuç:

- Örneklem varyansı hesaplanırken n adet bağımsız karesel sapma yoktur.
- Sonuncu sapma değeri $(x_n - \bar{x})$, ilk $n - 1$ tanesi tarafından zaten belirlenmiş durumdadır.
- Bu nedenle, varyans hesaplanırken kullanılan bağımsız bilgi sayısı (serbestlik derecesi) n değil, $n - 1$ 'dir.

Örnek:

Bir mühendis, bir pH metrenin "yanlılığını" (bias) test etmekle ilgilenmektedir. Veriler, nötr bir maddenin ($\text{pH} = 7.0$) pH değeri ölçülerek cihaz üzerinde toplanmıştır. $n = 10$ boyutunda bir örneklem alınmış ve sonuçlar şu şekilde elde edilmiştir:

7.07 7.00 7.10 6.97 7.00 7.03 7.01 7.01 6.98 7.08.

7.07 7.00 7.10 6.97 7.00 7.03 7.01 7.01 6.98 7.08.

Örneklem ortalaması $\bar{x}$ şu şekilde hesaplanır:

$$\bar{x} = \frac{7.07 + 7.00 + 7.10 + 6.97 + 7.00 + 7.03 + 7.01 + 7.01 + 6.98 + 7.08}{10} = 7.0250$$

Örneklem varyansı s^2 şu şekilde hesaplanır:

$$s^2 = \frac{1}{10 - 1} \sum_{i=1}^{10} (x_i - 7.0250)^2$$

$$s^2 = \frac{1}{9} [(7.07 - 7.025)^2 + (7.00 - 7.025)^2 + \dots + (7.08 - 7.025)^2] = 0.001939$$

Örneklem standart sapması s şu şekilde hesaplanır:

$$s = \sqrt{0.001939} = 0.044$$

Böylece, $n - 1 = 9$ serbestlik derecesi ile örneklem standart sapması **0.0440** olarak bulunur.

Örnek:

Aşağıdaki ölçümler, belirli bir markaya ait lateks boyanın saat cinsinden kuruma süresi için kaydedilmiştir. Bu ölçümlerin basit bir rastgele örneklem olduğunu varsayınız.

Veri Seti:

3.4 2.5 4.8 2.9 3.6

2.8 3.3 5.6 3.7 2.8

4.4 4.0 5.2 3.0 4.8

Soru:

Örneklem varyansını (s^2) ve örneklem standart sapmasını (s) hesaplayınız.

3.4	2.5	4.8	2.9	3.6
2.8	3.3	5.6	3.7	2.8
4.4	4.0	5.2	3.0	4.8

Örneklem boyutu $n = 15$.

Örneklem ortalaması:

$$\bar{x} = \sum_{i=1}^n \frac{x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

$$\bar{x} = \frac{1}{15}(3.4 + 2.5 + 4.8 + \cdots + 4.8) = 3.787. \text{ saat}$$

3.4	2.5	4.8	2.9	3.6
2.8	3.3	5.6	3.7	2.8
4.4	4.0	5.2	3.0	4.8

Örneklem boyutu $n = 15$.

$$\bar{x} = 3.787. \text{ saat}$$

Örneklem varyansı:

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

$$s^2 = \frac{1}{15-1} [(3.4 - 3.787)^2 + (2.5 - 3.787)^2 + (4.8 - 3.787)^2 + \dots + (4.8 - 3.787)^2] = 0.94284$$

Örneklem standart sapması:

$$s = \sqrt{s^2} = \sqrt{0.9428} = 0.971. \text{ saat}$$

Örnek:

Su emiciliği, bir lifin en önemli özelliklerinden biridir. 20 adet pamuk elyafı parçasından oluşan rastgele bir örneklem alınmış ve her bir parçanın emiciliği ölçülmüştür.

Emicilik Değerleri:

18.71	21.41	20.72	21.81	19.29	22.43	20.17
23.71	19.44	20.50	18.92	20.33	23.00	22.85
19.25	21.77	22.11	19.77	18.04	21.12	

Soru:

Bu örneklem için örneklem varyansını ve standart sapmasını hesaplayınız.

18.71	21.41	20.72	21.81	19.29	22.43	20.17
23.71	19.44	20.50	18.92	20.33	23.00	22.85
19.25	21.77	22.11	19.77	18.04	21.12	

Örneklem boyutu $n = 20$.

$$\bar{x} = \sum_{i=1}^n \frac{x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Örneklem ortalaması = 20.7675

18.71	21.41	20.72	21.81	19.29	22.43	20.17
23.71	19.44	20.50	18.92	20.33	23.00	22.85
19.25	21.77	22.11	19.77	18.04	21.12	

Örneklem ortalaması = 20.7675

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

$$s^2 = \frac{1}{20-1} [(18.71 - 20.7675)^2 + (21.41 - 20.7675)^2 + \dots + (21.12 - 20.7675)^2] = 2.5329$$

Örneklem varyansı = 2.5329

$$s = \sqrt{2.5345} = 1.5915.$$

Örneklem standart sapması = 1.5915

Örnek:

Uçak tahliye sistemleri için kullanılan belirli bir polimerin yaşlanma sürecine dirençli olması kritik bir öneme sahiptir. Deneyde yirmi adet polimer numunesi kullanılmıştır. On tanesi rastgele seçilerek yüksek sıcaklıklara maruz bırakılan (10 gün boyunca) hızlandırılmış bir yaşlanma sürecine dahil edilmiştir. Numunelerin çekme mukavemeti ölçümleri PSI (pound-kuvvet/inç kare) cinsinden kaydedilmiştir.

Yaşlanma işlemi uygulanmamış (No aging):

227	222	218	217	225
218	216	229	228	221

Yaşlanma işlemi uygulanmış (Aging):

219	214	215	211	209
218	203	204	201	205

1 inç = 2.54 cm

1 pound = 454 gr

1 atm = 1,01325 bar = 14,6959 psi

Yaşlanma işlemi uygulanmamış:

227	222	218	217	225
218	216	229	228	221

Yaşlanma işlemi uygulanmış:

219	214	215	211	209
218	203	204	201	205

- (a) Her iki veri seti için örneklem varyansını ve standart sapmasını hesaplayınız.
- (b) Veri değişkenliği hakkında yorum yapınız.

(a) Her iki grup için de çekme mukavemetindeki örneklem varyansını ve standart sapmasını hesaplayınız.

No aging:

227	222	218	217	225
218	216	229	228	221

Örneklem boyutu $n = 10$.

Aging:

219	214	215	211	209
218	203	204	201	205

Örneklem boyutu $n = 10$.

$$\bar{x} = \sum_{i=1}^n \frac{x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Ortalama (uygulanmış) = 209.90

Ortalama (uygulanmamış) = 222.10

Yaşlanma işlemi uygulanmamış:

227	222	218	217	225
218	216	229	228	221

Örneklem boyutu $n = 10$.

Yaşlanma işlemi uygulanmış:

219	214	215	211	209
218	203	204	201	205

Örneklem boyutu $n = 10$.

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

$$s_{\text{No Aging}}^2 = \frac{1}{10-1} [(227 - 222.10)^2 + (222 - 222.10)^2 + \dots + (221 - 222.10)^2] = 23.66$$

$$s_{\text{No Aging}} = \sqrt{23.62} = 4.86$$

$$s_{\text{Aging}}^2 = \frac{1}{10-1} [(219 - 209.90)^2 + (214 - 209.90)^2 + \dots + (205 - 209.90)^2] = 42.10$$

$$s_{\text{Aging}} = \sqrt{42.12} = 6.49$$


b) Yaşlanmanın çekme mukavemetindeki değişkenliği (variability) etkilediğine dair herhangi bir kanıt var mıdır?

$$s_{\text{No Aging}} = \sqrt{23.62} = 4.86$$

$$s_{\text{Aging}} = \sqrt{42.12} = 6.49$$

× uygulanmamış

○ uygulanmış



Standart sapma değerlerine göre, "Yaşlanma Uygulanmayan" grubundaki değişkenlik, "Yaşlanma Uygulanan" grubuna göre daha düşüktür. Bu fark nokta grafiğinde (dot plot) açıkça görülmektedir.

1.5. Kesikli ve Sürekli Veri

Veri toplama sürecinde elde edilen bilgiler, çalışılan alana bağlı olarak iki ana kategoriye ayrılır:

- **Sürekli (Continuous) Veri:** * Bir kimya mühendisinin ürün verimini (yield) en üst düzeye çıkarmak için yaptığı deneyi düşünelim.
 - Burada verim; yüzde, gram veya pound gibi birimlerle ifade edilir ve bir sayı doğrusu (süreklilik) üzerindeki herhangi bir değeri alabilir.
 - Ölçüme dayalıdır.
- **Kesikli (Discrete) Veri:** * Bir toksikoloğun yürüttüğü ilaç deneyi örneğini ele alalım.
 - Bazı durumlarda veriler "ikili" (binary) yapıdadır; yani hasta ilaca ya yanıt verir ya da vermez.
 - Saymaya dayalıdır ve genellikle tam sayılarla ifade edilir.

Veri Türlerinin Karşılaştırılması

Özellik	Kesikli (Discrete) Veri	Sürekli (Continuous) Veri
Tanım	Sadece belirli (tam) değerleri alan verilerdir.	Belirli bir aralıktaki her türlü değeri alabilen verilerdir.
Elde Edilme Yolu	Genellikle sayma yoluyla elde edilir.	Genellikle ölçme yoluyla elde edilir.
Örnekler	Hatalı parça sayısı, bir sınıftaki öğrenci sayısı.	Boy, ağırlık, sıcaklık, zaman, basınç.

Önemli Notlar:

- **Kesikli Veri:** Arada değer alamaz. Örneğin, bir ailedeki çocuk sayısı 2 veya 3 olabilir; ancak 2.5 olamaz. Genellikle "kaç tane?" sorusuna yanıt verir.
 - **Sürekli Veri:** Ölçüm cihazının hassasiyetine bağlı olarak sonsuz sayıda ara değer alabilir. Örneğin, bir boya kuruma süresi 3 saat de olabilir, 3.142 saat de olabilir.
-

Örneklem Oranı

İkili verinin istatistiksel analizini gerektiren pek çok uygulama vardır. Genellikle analizde kullanılan ölçüm *örneklem oranı*'dır.

İkili durum, iki kategori içerir.

Eğer veri

n birim içeriyorsa ve

x kategori 1'e düşen very sayısı ise,

$n - x$ kategori 2'ye düşen very sayısı olacaktır.

Böylece,

x/n

kategori 1 için örneklem oranıdır, ve

$1 - (x/n)$

kategori 2 için örneklem oranıdır.

Böylece,

 x/n kategori 1 için örneklem oranıdır, ve
 $1 - (x/n)$ kategori 2 için örneklem oranıdır.

Örnek:

Biyomedikal bir uygulamada 50 hasta örneklem birimlerini oluşturmaktadır. Tüm hastalara ilaç verildikten sonra bu 50 hastadan 20'si mide rahatsızlığında iyileşme göstermiştir.

Bu durumda, ilacın başarılı olduğu örneklem oranı $20 / 50 = 0.4$ 'tür.

İlacın başarılı olmadığı örneklem oranı ise $1 - 0.4 = 0.6$ 'dır.

Örnek:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0. \quad \text{olduğunu göster.}$$

Çözüm:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

$$\sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} = 0$$

$$\sum_{i=1}^n x_i - n\bar{x} = 0$$

$$\sum_{i=1}^n x_i - n \frac{1}{n} \sum_{i=1}^n x_i = 0$$

$$\sum_{i=1}^n x_i - \sum_{i=1}^n x_i = 0$$

$$0 = 0$$

Örnek:

Bir lastik üreticisi belli büyüklükteki lastiğin iç çapını belirlemek istemektedir. İdeal olan çapın 570 mm olmasıdır. Veri aşağıdaki gibidir:

572 572 573 568 569 575 56 570

- (a)Örneklem ortalamasını ve medyanını bulunuz.
- (b)Örneklem varyansını, standart sapmasını ve aralığını bulunuz.
- (c)Yapılan (a)ve (b)hesaplamalarını kullanarak,lastiklerin kalitesi hakkında yorum yapabilir misiniz?

(a).

Veriler aşağıdaki gibidir:

572◁ 572◁ 573◁ 568◁ 569◁ 575◁ 565◁ 570▷

Örneklem boyutu $n = 8$.

$$\bar{x} = \sum_{i=1}^n \frac{x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

$$\text{Ortalama} = \bar{X} = 570.5$$

565◁ 568◁ 569◁ 570, 572◁ 572◁ 573◁ 575▷

$$\tilde{x} = \begin{cases} x_{(n+1)/2}, & \text{if } n \text{ is odd,} \\ \frac{1}{2}(x_{n/2} + x_{n/2+1}), & \text{if } n \text{ is even.} \end{cases}$$

$$\text{Medyan} = \tilde{X} = 571$$

(b).

Veriler aşağıdaki gibidir :

572◁ 572◁ 573◁ 568◁ 569◁ 575◁ 565◁ 570▷

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

$$\text{Varyans} = s^2 = 10$$

$$s = \sqrt{s^2}$$

$$\text{Standart sapma} = s = 3.162$$

$$\text{Aralık} = 10$$

(c) ?

Veriler aşağıdaki gibidir :

572◁ 572◁ 573◁ 568◁ 569◁ 575◁ 565◁ 570▷

$$\text{Ortalama} = \bar{X} = 570.5$$

$$\text{Medyan} = \tilde{X} = 571$$

$$\text{Varyans} = s^2 = 10$$

$$\text{Standart sapma} = s = 3.162$$

$$\text{Aralık} = 10$$

Çap değerlerinin değişkenliği yüksektir, kalite hakkında soru işareti vardır.

Örnek:

Uyku düzeni üzerine sigaranın etkileri hakkında bir çalışma yapılmaktadır. Gözlenen ölçümler uykuya dalmada dakika cinsinden geçen süredir. Aşağıdaki veriler elde edilmiştir.

İçenler:

69.3	56.0	22.1	47.6
53.2	48.1	52.7	34.4
60.2	43.8	23.2	13.8

İçmeyenler:

28.6	25.1	26.4	34.9
29.8	28.4	38.5	30.2
30.6	31.8	41.6	21.1
36.0	37.9	13.9	

- Her grup için örneklem ortalamalarını hesaplayınız.
- Her grup için örneklem standart sapmalarını hesaplayınız.
- Nokta grafiğini çiziniz.
- Uykuya dalma süresine, sigaranın nasıl bir etkisi olduğu hakkında yorum yapınız.

(a).

İçenler:

69.3	56.0	22.1	47.6
53.2	48.1	52.7	34.4
60.2	43.8	23.2	13.8

İçmeyenler:

28.6	25.1	26.4	34.9
29.8	28.4	38.5	30.2
30.6	31.8	41.6	21.1
36.0	37.9	13.9	

Örneklem boyutu $n = 12$.

Örneklem boyutu $n = 15$.

$$\bar{x} = \sum_{i=1}^n \frac{x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

$$\bar{X}_{\text{İçenler}} = 43.70 \text{ Dak.}$$

$$\bar{X}_{\text{İçmeyenler}} = 30.32 \text{ Dak.}$$

(b).

İçenler:

69.3	56.0	22.1	47.6
53.2	48.1	52.7	34.4
60.2	43.8	23.2	13.8

İçmeyenler:

28.6	25.1	26.4	34.9
29.8	28.4	38.5	30.2
30.6	31.8	41.6	21.1
36.0	37.9	13.9	

$$s^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}$$

$$s = \sqrt{s^2}$$

$s_{\text{İçenler}}$

$= 16.93$

Dak.

$s_{\text{İçmeyenler}}$

$= 7.13$

Dak.

(c).

İçenler:


69.3	56.0	22.1	47.6
53.2	48.1	52.7	34.4
60.2	43.8	23.2	13.8

$s_{\text{İçenler}} = 16.93$

İçmeyenler:

28.6	25.1	26.4	34.9
29.8	28.4	38.5	30.2
30.6	31.8	41.6	21.1
36.0	37.9	13.9	

$s_{\text{İçmeyenler}} = 7.13$



“o” İçenler

“x” İçmeyenler

(d).

İçenler:

69.3	56.0	22.1	47.6
53.2	48.1	52.7	34.4
60.2	43.8	23.2	13.8

$\bar{X}_{\text{İçenler}} = 43.70$


$s_{\text{İçenler}} = 16.93$

İçmeyenler:

28.6	25.1	26.4	34.9
29.8	28.4	38.5	30.2
30.6	31.8	41.6	21.1
36.0	37.9	13.9	

$\bar{X}_{\text{İçmeyenler}} = 30.32$

$s_{\text{İçmeyenler}} = 7.13$



“o” İçmeyenler
“x” İçenler

İçenlerin uykuya dalması daha uzun zaman almaktadır, ve içenlerin uykuya dalma süresi daha değişkendir.